

Predicción de la Demanda Energética en España mediante Machine Learning

Autor: Marta Requejo Merino

Grado: Inteligencia Artificial y Big Data

1. Introducción y Objetivos del Proyecto.....	3
2. Instrucciones de Ejecución.....	3
2.1. Requisitos Previos.....	3
2.2. Secuencia de Trabajo.....	3
3. Arquitectura del Sistema.....	4
4. Estructura.....	4
4.1. AWS.....	4
4.2. Análisis y Modelado.....	5
4.3. Despliegue.....	6
5. Tecnologías usadas.....	6
6. Metodología y Desarrollo.....	9
6.1. Preparación de los Datos (AWS).....	9
6.2. Desarrollo y Experimentación (Cuaderno Jupyter).....	9
7. Enlaces útiles.....	10
8. Conclusión.....	10

1. Introducción y Objetivos del Proyecto

El objetivo principal de este proyecto es desarrollar un modelo de Inteligencia Artificial capaz de predecir la demanda de energía eléctrica a nivel nacional en España. Se trata de un problema de regresión sobre series temporales, donde la **variable objetivo** es la **carga total real** expresada en **Megavatios (MW)**.

En el sector eléctrico, el balance entre oferta y demanda debe ser exacto en tiempo real. Una predicción precisa permite a los operadores planificar el mix de generación, reducir la dependencia de centrales térmicas de respaldo y maximizar la integración de fuentes de energía renovable.

2. Instrucciones de Ejecución

2.1. Requisitos Previos

Entorno: Configurar un entorno virtual de Python e instalar las librerías especificadas en el archivo `requirements.txt`

Credenciales: Disponer de un archivo `.env` en la raíz del proyecto con las claves de acceso a AWS necesarias para la ingesta y el procesamiento en la nube. El proyecto incluye una plantilla con los datos necesarios a rellenar llamado `.env.plantilla`

2.2. Secuencia de Trabajo

Orquestación del Data Lake y ETL (`pipeline_aws.py`):

- Este script centralizado ejecuta el flujo completo en la nube:
 - **Ingesta:** Carga los archivos crudos (`energy_dataset.csv` y `weather_features.csv`) a S3, organizándolos en una estructura particionada.
 - **Catalogación:** Lanza el *Crawler* de AWS Glue para registrar los datos en el catálogo.
 - **Transformación:** Ejecuta las sentencias SQL en Amazon Athena para limpiar, consolidar y generar la tabla `dataset_unificado` en formato Parquet, optimizada para el modelado.

***Nota:** este punto puede requerir de bastante tiempo mientras se ejecuta el Script

Desarrollo y Modelado (**cuadernos de hitos**):

- Hito 1
- Hito 2
- Hito 3

En este punto se recomienda ejecutar el cuaderno proyecto.ipynb, pero en su defecto se pueden ejecutar los cuadernos en orden.

Despliegue e Interfaz (Hugging Face):

- Una vez validados los modelos en el Hito 3, se utiliza el script de despliegue en **Hugging Face Spaces**. Este componente carga el modelo para permitir la inferencia en tiempo real a través de una interfaz gráfica desarrollada en **Gradio**.

3. Arquitectura del Sistema

El ciclo de vida del proyecto se ha dividido en tres entornos diferenciados para garantizar la escalabilidad, reproducibilidad y un despliegue profesional:

- **Entorno Cloud de Ingesta (AWS):** Utilización de Amazon S3 como repositorio seguro en la nube para el almacenamiento de los datasets originales en crudo (datos de 2015 a 2018).
- **Análisis y Modelado:** Espacio de análisis mediante un cuaderno de Jupyter donde se realiza el preprocesamiento, la ingeniería de características y el entrenamiento de los modelos.
- **Despliegue:** Alojamos en Hugging Face una interfaz gráfica con Gradio en la cual tenemos el modelo integrado para poder interactuar con el modelo.

4. Estructura

4.1. AWS

Bucket S3: **energia-espana**

- **raw/**: Almacena los datos originales particionados temporalmente para optimizar la lectura (**year=.../month=.../day=.../data.csv**).

- `energia/`
- `meteorologia/`
- **`processed/`**: Almacena los resultados de las transformaciones SQL de Athena en formato Parquet, optimizado para el consumo analítico.
 - **`dataset-unificado/`**
- **`athena_output/`**: Carpeta técnica obligatoria requerida por Amazon Athena para almacenar temporalmente los metadatos de las ejecuciones, el histórico de consultas y los resultados intermedios de las sentencias SQL.

4.2. Análisis y Modelado

- **`proyecto energia/`**
 - **`data/`** - Datos brutos originales descargados de AWS S3.
 - **`datos_procesados/`** - Datasets procesados
 - `datos_test_procesados.csv` - datos generados para el modelo con memoria
 - `datos_limpios_hito01.csv` - datos resultantes del cuaderno 1
 - `test_df_hito02.csv` - datos resultantes del cuaderno 2
 - **`modelos/`** - Modelos exportados y sus escaladores.
 - `modelo_energia_es_lag.json`
 - `escalador_energia_es_lag.pkl`
 - `modelo_energia_es.json`
 - `escalador_energia_es.pkl`
 - **`scripts/`**
 - `script_energia.py` - Scripts para la conexión con AWS, creación de bucket, crawlers, athena y procesamiento de datos
 - **`notebooks/`**
 - `hito0.ipynb`
 - `hito1.ipynb`
 - `hito2.ipynb`
 - `hito3.ipynb`
 - `proyecto.ipynb`
 - **`.env.plantilla`** - Plantilla para los secretos del proyecto
 - **`requirements.txt`** - Dependencias del proyecto.
 - **`README.md`** - Documentación general.

4.3. Despliegue

proyecto_energia/

- **datos_procesados/** - Dataset procesado para el modelo entrenado (con lags)
 - **datos_test_procesados.csv**
- **modelos/** - Modelos y escaladores
- **app.py** - Motor principal de la aplicación Gradio.
- **requirements.txt** - Dependencias para el contenedor de Hugging Face.
- **README.md** - Portada del proyecto y configuración YAML del Space.

5. Tecnologías usadas

Tecnología / Librería	Rol en el Proyecto	Justificación de su elección
AWS S3	Almacenamiento Cloud (Data Lake)	Servicio de almacenamiento altamente escalable. Soporta el almacenamiento inmutable de datos en crudo (raw) y formatos optimizados (Parquet).
AWS Glue	Catálogo de Datos	Gestión automatizada de metadatos mediante Crawlers para el descubrimiento automático de esquemas sobre archivos en S3.
Amazon Athena	Motor de Consultas	Permite ejecutar sentencias SQL distribuidas directamente sobre S3 para limpiar,

		pivotar y unificar los datasets de energía y clima sin gestionar servidores.
Boto3	SDK Oficial de AWS	Librería fundamental para interactuar con la API de AWS de forma programática y automatizar la ejecución del pipeline ETL.
Python-Dotenv	Seguridad de Credenciales	Permite cargar variables de entorno desde un archivo local .env , evitando la exposición accidental de claves de acceso de AWS en el código.
Pandas	Manipulación de Datos	Estructura y manipula los datos en dataframes eficientemente para la limpieza final, imputación de nulos y ordenación temporal.
NumPy	Cálculo Numérico Vectorizado	Librería matemática subyacente que optimiza las operaciones algebraicas vectorizadas y la gestión de arreglos en el preprocesamiento.
Scikit-Learn	Preprocesamiento y Escalado	Proporciona utilidades fundamentales como escaladores numéricos (StandardScaler/MinMaxScaler) y métricas de

		evaluación del rendimiento.
Holidays	Ingeniería de Características	Permite identificar e integrar automáticamente las festividades oficiales españolas en el dataset.
Matplotlib	Visualización Gráfica	Librería base para generar gráficos estáticos esenciales, como curvas de demanda histórica e histogramas de distribución.
Seaborn	Visualización Estadística	Extensión de Matplotlib.
XGBoost	Modelo Predictivo	Algoritmo basado en Gradient Boosting sobre árboles de decisión, líder en la industria por su precisión y eficiencia en datos tabulares complejos.
Joblib	Serialización de Objetos	Permite exportar y guardar de forma óptima los escaladores entrenados en archivos binarios (.pkl) para su posterior consumo en producción.
Gradio	Interfaz de Usuario (UI)	Facilita la creación ágil de interfaces web interactivas en Python para interactuar visualmente con el motor predictivo.

Hugging Face Spaces	Infraestructura de Despliegue	Plataforma que hospeda la aplicación mediante contenedores, permitiendo un acceso web público de manera gratuita y permanente.
----------------------------	-------------------------------	--

6. Metodología y Desarrollo

6.1. Preparación de los Datos (AWS)

El flujo de datos comienza con la ingesta particionada en S3. Posteriormente, un AWS Glue Crawler mapea la estructura de los datos crudos creando un catálogo virtual. Utilizando Amazon Athena, se ejecutan sentencias para filtrar registros nulos, consolidar la información meteorológica y unirla con la demanda eléctrica. El resultado se exporta en formato Parquet, reduciendo el volumen de lectura y acelerando el entrenamiento posterior.

6.2. Desarrollo y Experimentación (Cuaderno Jupyter)

Todo el análisis de la información, el diseño experimental y el entrenamiento del sistema se centralizan por completo dentro del cuaderno [proyecto.ipynb](#). Este entorno funciona como el laboratorio principal de desarrollo, donde se ejecutan de manera integrada las siguientes tareas:

- **Análisis de la Información y Limpieza Final:** Inspección directa sobre los datos unificados para comprender su comportamiento estacional, estudiar las tendencias generales y asegurar la consistencia del set de datos antes de configurar cualquier algoritmo.
- **Creación de Variables:** Diseño e integración de nuevos indicadores temporales y factores de contexto extraídos a partir del código para enriquecer la información de entrada y dotar al sistema de una mayor capacidad predictiva.
- **Entrenamiento y Comparativa:** Fase de experimentación donde se implementan y evalúan diferentes soluciones algorítmicas, permitiendo contrastar el rendimiento de modelos sencillos frente a arquitecturas más complejas sobre el conjunto de datos de prueba.
- **Optimización Final:** Ajuste automático de los parámetros internos de la solución seleccionada para exprimir al máximo su precisión y reducir el margen de error antes de exportar los archivos definitivos para su posterior explotación.

*Nota: También se han incluido en el proyecto los cuadernos correspondientes a sus respectivos hitos por separado, con la misma funcionalidad que el cuaderno principal. Llamado `proyecto.ipynb`

7. Enlaces útiles

Estos enlaces son los correspondientes al proyecto:

- [Repositorio del proyecto](#) (cuaderno, script de subida).
- [Repositorio de la Interfaz de Gradio](#).
- [Origen de los datos del proyecto](#).

Estos enlaces son útiles si se quiere probar la precisión del modelo con datos reales:

- [Web de AEMET de temperatura de los últimos días](#)
- [Web de AEMET con la temperatura actual](#)
- [Web de red eléctrica para comprobar el consumo](#)

8. Conclusión

Lo que hemos conseguido con este proyecto es cerrar el círculo completo de un producto basado en datos, desde que los archivos llegan en bruto a la nube hasta que el modelo está listo para predecir. Lo que más se ha visto aquí no es solo que el sistema funciona, sino que el éxito real de una predicción depende de cómo tratamos la información. En nuestro caso, la "memoria" del consumo pasado y el contexto (clima y calendario) son los que realmente hacen que el modelo acierte.

Más allá de la parte técnica, el objetivo de fondo es demostrar que con las herramientas adecuadas podemos gestionar mejor la energía. Anticipar la demanda no es solo un reto de programación, es una pieza clave para que el sistema eléctrico sea más eficiente y se aproveche mejor la energía. Este proyecto es una muestra real de cómo la Inteligencia Artificial puede ayudarnos a tomar decisiones mucho más inteligentes en un sector tan crítico como el de la energía.